PEMBELAJARAN
MESIN I

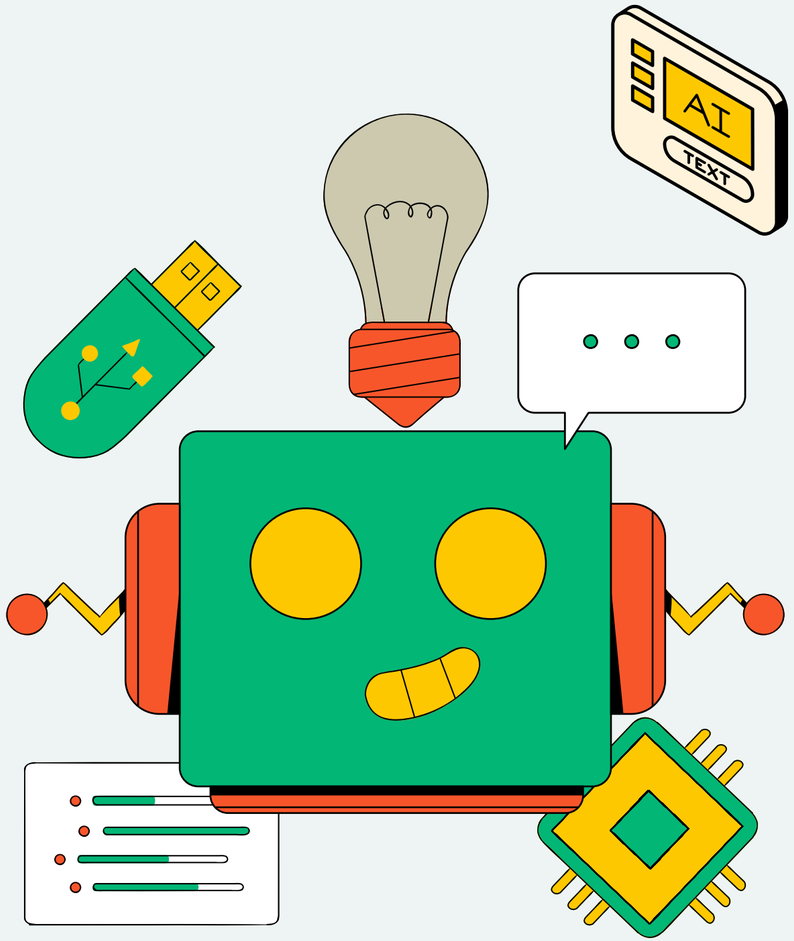

REGRESI LINEAR

PRESENTED BY:

KELOMPOK 8

DATASET: SGEMM GPU KERNEL PERFORMANCE

- Mengukur waktu eksekusi perkalian matriks 2048 kali 2048 pada GPU dengan variasi parameter kernel.
- Dataset besar dengan 241.600 baris dan 14 fitur input (Konfigurasi Tiling, Optimasi Kernel, dan Akses Memori).
- Performa GPU dipengaruhi oleh interaksi antar-parameter yang bersifat non-linear dan kompleks.
- Empat kolom runtime (Run1-Run4) digabungkan melalui rata-rata (averaging) dengan tujuan untuk mengurangi variasi eksperimen (experimental noise) untuk mendapatkan estimasi target yang lebih stabil dan reliabel.

PREPROCESSING & PIPELINE PREPROCESSING

Stabilitas Numerik melalui Standardisasi Fitur

- Transformasi Skala menggunakan StandardScaler untuk mengubah fitur menjadi rata-rata 0 dan standar deviasi 1.
- Urgensi pada Regresi untuk mencegah koefisien yang tidak seimbang dan menghindari bias model terhadap fitur dengan magnitude besar.
- Optimisasi Huber untuk mempercepat konvergensi pada model berbasis iterasi (seperti Huber Regressor) agar gradien tidak didominasi oleh fitur bernilai ekstrem.

PREPROCESSING & PIPELINE PREPROCESSING

Validitas Eksperimen dengan Sklearn Pipeline

- Arsitektur Pipeline: Integrasi StandardScaler dan Regressor dalam satu kesatuan modular.
- Pencegahan Data Leakage dengan scaling yang hanya dilakukan pada data train di setiap fold selama cross-validation.
- Keunggulan Metodologis yaitu untuk menghindari bocornya informasi statistik (mean/std) dari data uji ke data latih dan untuk menjamin estimasi performa model yang mencerminkan kemampuan generalisasi yang sebenarnya, bukan hasil yang terlalu optimistis.
- Kesimpulan: Preprocessing ini menjaga stabilitas numerik dan validitas hasil eksperimen secara sistematis.

LOG PROMPT

Prompt 1: Fase Eksploratif

- Membandingkan 5 model (OLS, Ridge, Lasso, ElasticNet, Huber).
- Implementasi Pipeline modular dengan StandardScaler.
- Pengujian dalam dua fase: Normal dan Stress Test.

Prompt 2: Fase Optimasi & Fokus

- Penyederhanaan menjadi 2 model utama: OLS (Baseline) vs Huber Regressor (Robust).
- Fokus pada perbandingan mendalam antara regresi standar dan regresi tangguh.
- Mempertahankan validitas melalui K-Fold Cross Validation.

KETERBARUAN & MODIFIKASI KODE

Peningkatan Struktur dan Efisiensi Kode

Clean Code (Single Point of Control)

- Modifikasi: Penggunaan dictionary CONFIG untuk manajemen parameter (path data, % outlier, nama file output).
- Manfaat: Memudahkan kontrol eksperimen tanpa mengubah ratusan baris kode.

Efisiensi Memori (Memory Optimization)

- Modifikasi: Mengubah tipe data dari float64 menjadi np.float32 saat pembacaan CSV.
- Manfaat: Menghemat penggunaan RAM, memastikan kode berjalan lancar di lingkungan terbatas seperti Google Colab.

KETERBARUAN & MODIFIKASI KODE

Visualisasi, Persistence, & Pengujian Ketahanan

Visualisasi & Data Persistence

- Modifikasi: Integrasi Matplotlib/Seaborn untuk grafik perbandingan MAPE dan ekspor otomatis hasil ke file .csv.
- Manfaat: Mempermudah analisis stabilitas model secara visual dan penyimpanan data eksperimen untuk dokumentasi.

Fungsi Stress Test Manual (Robustness Testing)

- Modifikasi: Penambahan fitur inject_stress=True untuk simulasi anomali/outlier secara sengaja.
- Manfaat: Menguji secara objektif model mana yang paling kuat bertahan dalam kondisi data terburuk (simulasi kegagalan sensor/noise).

EXPERIMENT LOG

No	Model	Kondisi	MAE (ms)	RMSE (ms)	MAPE (%)	R^2 Score	Catatan
1	OLS (Baseline)	Normal	176.4055	283.8648	214.2634	0.4073	Model dasar tanpa regularisasi
2	Ridge (L2)	Normal	176.405	283.8648	214.2626	0.4073	Regularisasi L2
3	Lasso (L1)	Normal	176.3051	283.8648	214.0953	0.4073	Regularisasi L1
4	ElasticNet	Normal	172.3097	284.3067	207.499	0.4055	Kombinasi L1 & L2
5	Huber (Robust)	Normal	143.3698	315.9265	122.8216	0.2659	Robust terhadap outlier
6	OLS (Baseline)	Stress Test	248.3017	318.7454	326.1999	0.2526	Sensitif terhadap outlier
7	Ridge (L2)	Stress Test	248.3008	318.7446	326.1989	0.2526	Lebih stabil dari OLS
8	Lasso (L1)	Stress Test	248.1985	318.6512	326.0477	0.253	Penalti sparsity
9	ElasticNet	Stress Test	240.2086	312.4087	317.2543	0.282	Stabilitas menengah
10	Huber (Robust)	Stress Test	144.7073	311.6241	131.8638	0.2858	Paling stabil terhadap outlier

HASIL EKSPERIMEN

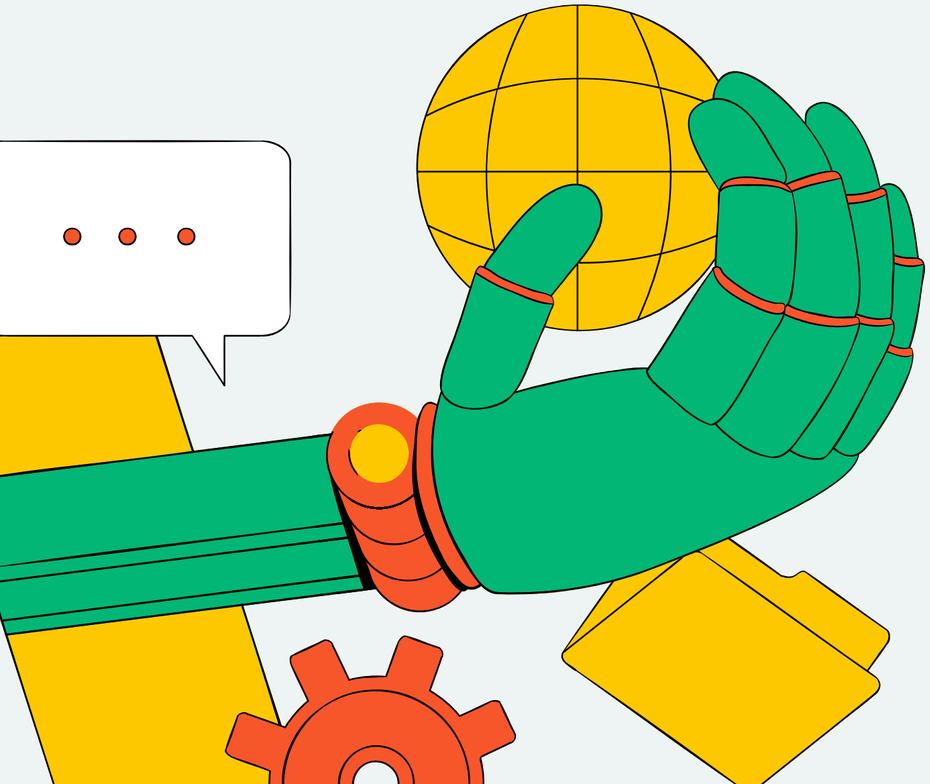

Tujuan Awal: Memverifikasi secara empiris temuan Ismail & Rasheed (2021) bahwa model Huber lebih unggul daripada OLS dalam kondisi data ber-outlier.

Parameter Model:

- OLS (Baseline): Tanpa regularisasi.
- Ridge & Lasso: Menggunakan penalti L2 dan L1 (alpha=0.1).
- Huber Regressor: Epsilon 1.35 untuk kontrol sensitivitas outlier.

Temuan Fase Normal:

- OLS, Ridge, dan Lasso menunjukkan performa identik ($R^2 \approx 0.4073$).
- Model klasik mampu menjelaskan 40% variasi data tanpa indikasi overfitting yang signifikan.

HASIL EVALUASI

PENGUJIAN KETAHANAN (ROBUSTNESS TESTING)

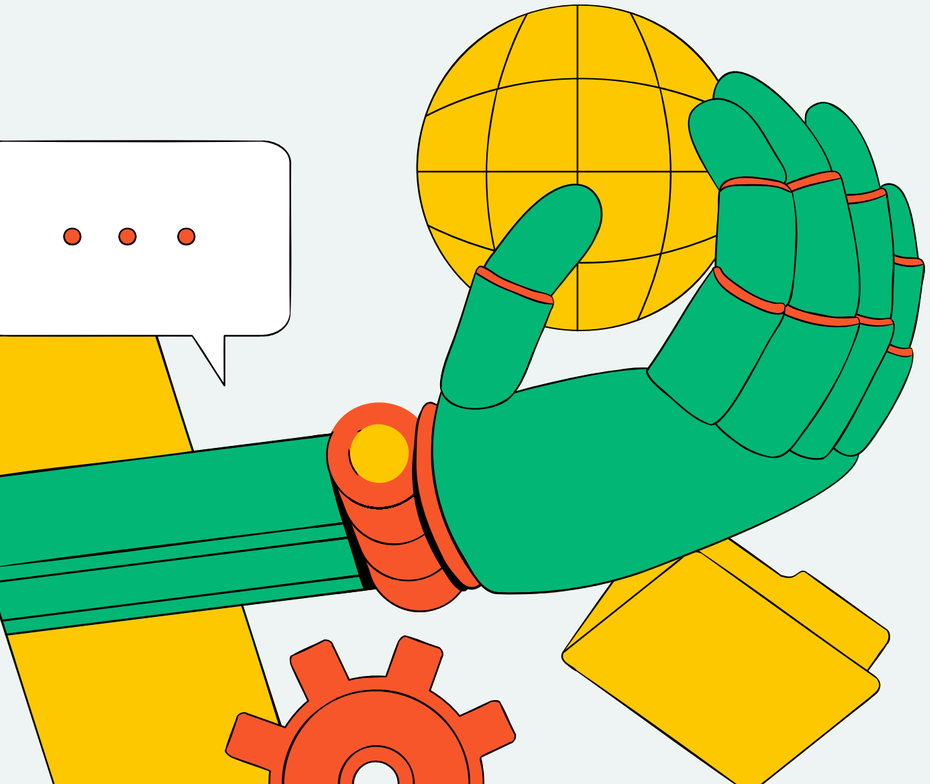

Dampak Injeksi Outlier (5%):

- Degradasi OLS: Nilai R^2 turun drastis dari 0.40 ke 0.25 karena OLS sangat sensitif terhadap kuadrat error besar.
- Stabilitas Huber: Tetap stabil dengan R^2 relatif lebih tinggi (~0.2858) pada kondisi kritis.

Analisis MAPE (Mean Absolute Percentage Error):

- MAPE OLS melonjak tajam hingga >300% saat stress test.
- Huber Regressor mampu bertahan di angka ~131%.
- Kesimpulan: Pendekatan Robust Regression terbukti lebih efektif dan stabil dalam mempertahankan akurasi prediksi di bawah tekanan data ekstrem.

PERBANDINGAN STRATEGI MODEL

Mekanisme Loss Function:

- OLS: Meminimalkan error kuadrat; sangat terpengaruh oleh pencilan ekstrem.
- Huber: Berperilaku seperti OLS pada error kecil, namun menjadi linear pada error besar (outlier) sehingga tidak didominasi nilai ekstrem.

- Fokus Analisis Akhir: Penelitian difokuskan pada perbandingan OLS vs Huber karena keduanya mewakili perbedaan teoritis mendasar dalam menangani noise data.

- Interpretasi: Stabilitas Huber dalam mempertahankan nilai MAE dan RMSE pada stress test menjadikannya pilihan model yang lebih reliabel untuk sistem GPU yang rentan terhadap variasi eksperimental.

MEKANISME STRESS TEST

Pengujian Ketahanan (Robustness Testing)

- Definisi & Prosedur:
  - Mengevaluasi ketahanan model terhadap anomali data ekstrem.
  - Mengidentifikasi 5% sampel acak dari dataset asli.
  - Injeksi Outlier: Nilai target dikalikan dengan faktor 10 untuk menciptakan pencilan buatan yang signifikan.
- Tujuan Simulasi:
  - Merepresentasikan kegagalan sensor atau kesalahan pencatatan data di dunia nyata.
  - Menilai efektivitas model dalam mempertahankan akurasi di bawah tekanan data yang terkontaminasi.
- Landasan Teoritis:
  - Sesuai dengan studi komparasi, OLS tidak tangguh terhadap penyimpangan asumsi normalitas akibat adanya outlier.

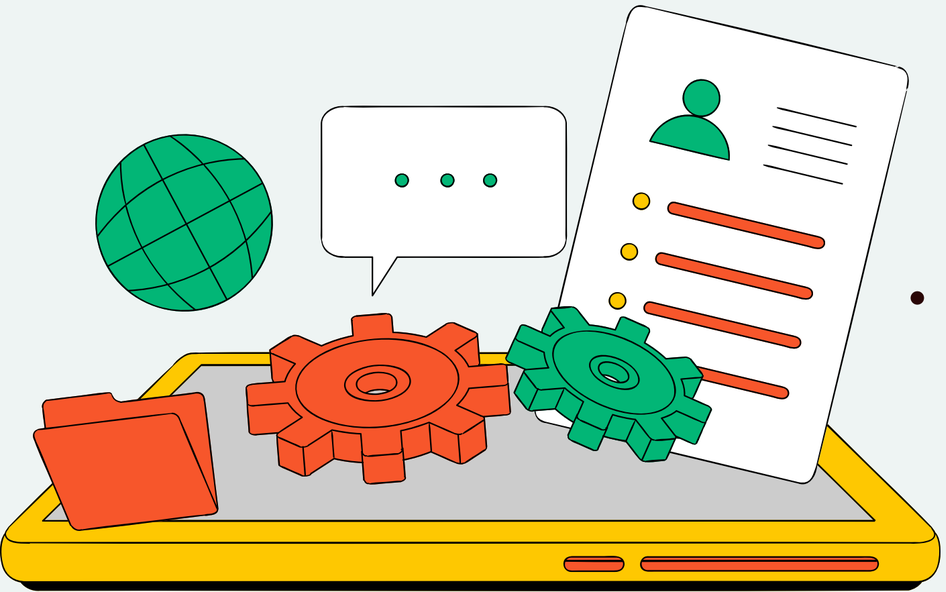

KESIMPULAN: MENGAPA HUBER LEBIH UNGGUL?

- Stabilitas Performa: Huber Regressor terbukti paling stabil terhadap outlier dengan peningkatan MAPE yang jauh lebih rendah dibandingkan OLS (131% vs 326%).
- Karakteristik Model: OLS sangat sensitif karena meminimalkan kuadrat error & Huber bertindak sebagai model robust yang membatasi pengaruh nilai residual ekstrem.
- Validitas Metodologis: Penggunaan Pipeline dan K-Fold Cross Validation berhasil mencegah data leakage dan menjamin objektivitas evaluasi.
- Rekomendasi: Untuk data performa GPU yang memiliki potensi noise eksperimental, model regresi tangguh (robust) memberikan hasil yang lebih representatif daripada regresi linier standar.
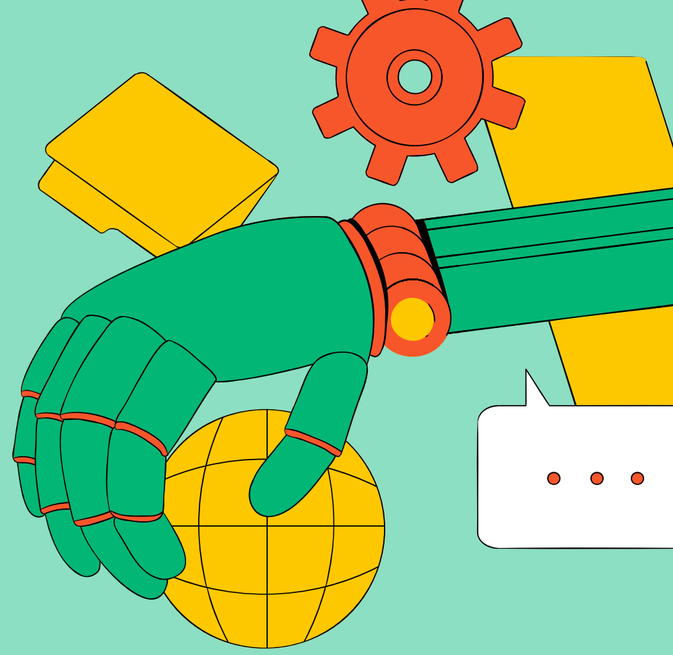
THANK YOU!